Cours n°9

Textes, langages formels et templates

Sommaire

INTRODUCTION

Bibliothèques de templates

Regex
Expression régulière
www.cplusplus.com/reference/regex/

Common Text Transformation Library (cttl)
Classe de chaînes de caractères avec marques et segments
Comparaison, insertion, modification et analyse à l'aide de grammaires EBNF
sourceforge.net/projects/cttl/

Yet another Object-Oriented Lex (YooLex)
Construction d'analyseurs lexicaux (cf. outil unix lex)
sourceforge.net/projects/yoolex/

Automata Standard Template Library (astl)
Construction et utilisation d'automates d'états finis
sourceforge.net/projects/astl/

DicoLib
Création et gestion de dictionnaires
sourceforge.net/projects/dicolib/

1.1 CLASSE NODE

Constructeurs et Accesseurs

Gestion de marques dans la chaîne
Nœud Identifié (numéro) correspondant à une position (offset) dans la chaîne

Constructeurs
Construction d'un noeud dans la string str à la position pos
node(string str, int pos)
Construction d'une copie du nœud n
node(node<T> n)
Construction d'une copie du nœud n avec une position différente
node(node<T> n, int pos)

Accesseurs
Accès au Conteneur input<T> **parent**()
Accès au numéro int **identity**()
Position int **offset**()
Numéro de ligne correspondant à la position int **line**()
Caractère d'indice i relativement à la position du noeud char **operator[]** (int i)

Gestion des positions des marques

Méthodes modifiant la position

int **offset(**int p**)**	Position du nœud à la valeur p
int **go_bof**()	Position du nœud au début du conteneur
int **go_eof**()	Position du nœud à la fin du conteneur
int **go_line_next**()	Position du nœud au début de la ligne suivante
int **go_line_previous**()	Position du nœud au début de la ligne précédente
int **go_line_home**()	Position du nœud au début de la ligne courante
int **go_line_home**(int l)	Position du nœud au début de la ligne l
int **go_line_end**()	Position du nœud à la fin de la ligne courante
int **go_line_end**(int l)	Position du nœud à la fin de la ligne l

Méthodes d'insertion de texte

Insertion d'un texte au début du noeud, décalage des positions des nœuds suivants
void **insert_stay**(string s)
Insertion d'un texte avant le nœud, décalage des positions des nœuds suivants
int **insert_go**(string s)

testNode.cpp

Lecture, création du conteneur et des marques

```
string texte;
cttl::file2string("Data/livres/adelaide.txt", texte);
node<> p1( texte ); p1.go_bof();
node<> p2( texte ); p2.go_eof();
cout << "ce texte comporte " << p2.offset() << " caractères et " ;
cout << p2.line()-1 << " lignes" << endl;

// lecture du caractère j de la ligne i
int i,j; cin >> i >> j; p1.go_line_home(i+1);
cout << p1.offset() << " " <<  p1[j] << endl;

// insertion et décalage
p1.insert_stay("insertion");
cout << p1.offset() << " " << p2.offset() << endl;
p1.insert_go("destruction");
cout << p1.offset() << " " << p2.offset() << endl;
```

```
ce texte comporte 46355 caractères et 192 lignes
10 4
4329 c
4329 46364
4340 46375
```


testNode2.cpp

Création du conteneur et conteneur de marques

```
ifstream fEntree("Data/livres/adelaide.txt");
string phrase, texte;
vector<node<> > vp;
int n = 0;
while (!fEntree.eof()) {
      getline(fEntree, phrase); phrase += "\n";
      vp.push_back(*(new node<>(texte)));
      vp[n].go_eof(); vp[n].insert_stay(phrase);
      n++;
}

for (int i = 0;i < n;i++)
cout << i << " " << vp[i].offset() << endl;
```

```
0 0
1 141
2 142
3 1160
4 1161
5 2800
6 2801
```


Composants

Deux spécialisations du patron de classes edge

const_edge : pas d'accesseurs en écriture (sauf casse)
edge : accesseurs en lecture et en écriture

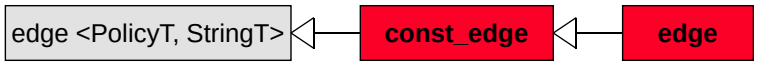

PolicyT (white space policy) : modélisation des commentaires

Constructeurs et Accesseurs (const_edge)

Gestion des segments de la chaîne (sous-chaînes)

Couple de marques (first et second) avec modélisation des commentaires

Constructeurs

Construction d'un segment entre deux marques d'un même conteneur
const_edge (node<T> md, node<T> mf)
Construction d'un segment dans la string str entre deux positions
const_edge (string str, int m1, int m2)

Construction d'un segment à partir d'un autre segment
const_edge (const_edge<T1, T2> e)

Accesseurs

Texte du segment	string **text**()
Longueur du segment	int **length**()
Passage du texte en majuscules	void **text_tolower**()
Passage du texte en minuscules	void **text_toupper**()
Gestionnaire des séparateurs	PolicyT **space_policy**()

testConst_Edge.cpp

Lecture, segmentation et création des segments

```
string texte;
cttl::file2string("Data/livres/adelaide.txt",texte);
int i1 = -1, i2, n = 0;
vector<const_edge<> > vs;
while ((i2 = texte.find('\n', i1+1)) != string::npos) {
      node<> p1(texte, i1+1); p1.offset(i1+1);
      node<> p2(texte, i2); p2.offset(i2);
      vs.push_back(*(new const_edge<>(p1, p2))); n++; i1 = i2;
}
// lecture de la ligne i
int i; cin >> i;
cout << vs[i].first.offset() << " " << vs[i].second.offset() << endl;
cout << vs[i].text() << endl;
```

```
6
2801 3981
Elle se dit: je ferai un heureux. J'aurai un esclave qui me devra
tout, et le premier succès et le premier bonheur et la première
gloire et la première expérience. Il m'adorera; et, si je l'adore,
je ne le lui dirai pas comme je le sens, et je régnerai sur lui. Je
l'entraînerai où il me plaira qu'il aille et je le connaîtrai à
fond: tête et coeur, bien et mal, vices et vertus. Des premiers je
```


Constructeurs et Accesseurs (edge)

Modification directe des textes d'un segment des

Constructeurs

Construction d'un segment entre deux marques d'un même conteneur
edge (node<T> md, node<T> mf)

Construction d'un segment dans la string str entre deux marques (numéro)
edge (string str, int m1, int m2)

Construction d'un segment à partir d'un autre segment

edge (edge<T1, T2> s) **edge** (const_edge<T1, T2> s)

Accesseurs text.

Modification du texte du segment	void **text**(string)
Echange des textes entre segments	void **text_swap**(edge<T1, T2> s)

Modélisation des commentaires (white space policy)

Commentaire

Chaînes de caractères n'appartenant pas au langage
Pas de prise en compte dans une analyse
Annotation dans un texte

Modélisation

Paramètre d'un segment de texte

Définition par défaut (pas de commentaire)	policy_default
Espace ou caractères de formatage	policy_space< flag_follow_space >
Commentaires C/C++/Java	policy_space< flag_cpp_comments
Description par l'utilisateur de segments de texte de commentaires (2 passes)	policy_space< flag_follow_region >
Insertion d'un segment de commentaires	void **region_insert**()
Destruction d'un segment de commentaires	void **region_erase**()
Texte du segment sans commentaires	string **region_difference** ()

Grammaires

Notation Extended Backus-Naur Form (EBNF)

Ensemble de règles de productions (rule)
variables,
symboles auxiliaires [ ] optionnel, {} zéro ou plus

$start = $mcmd | $dcmd | $icmd | $ecmd;
$mcmd = bouger $dir;
$dcmd = detruire [$item];
$icmd = inserer;
$ecmd = fin [inserer];
$dir = haut | bas | gauche | droite;
$item = caractere | mot | ligne | page;

Phrases du langage

{bouger haut, detruire mot, inserer, fin }

Fonction symbol()

Symbole terminal du langage

Implémentation avec une fonction lexème

Caractère quelconque	symbol()
Symbole vide	symbol(true)
Symbole stop	symbol(false)
Caractère c	symbol(char c)
Tableau de caractères tc	symbol(char* tc)
Chaîne de caractères s	symbol(string s)
symbole optionnel	*symbol(…)
symbole multiple	+symbol(…)

Opérateur de concaténation de symboles	(symbol(…) + symbol(…))
Opérateur logique entre symboles	(symbol(…) | symbol(…))

Position des symboles terminaux

Début du motif	first(char* tc)	first(string s)
Début du segment	begin()	
Fin du segment	end()	

testSymbol.cpp

Recherche de motifs dans un segment

Méthodes associées à un motif

int **match(**edge<T1, T2> s)	Appariement du segment avec un motif
int **find(**edge<T1, T2> s)	Recherche d'un motif dans le segment
int **bang_find(**edge<T1, T2> s)	Recherche successive de tous les motifs

Retour de la position du début du motif, position de la fin dans l'attribut first de s

```
string texte; file2string("Data/livres/adelaide.txt",texte);
// recherche d'une chaine de caracteres
edge<> e = *(new edge<>(texte, 0, texte.size()));

int p = symbol("Hautcastel").find(e);
cout << p << " " << texte.substr(p, e.first.offset()-p) << endl;

// recherche en boucle du motif a{n}
while ((p = (symbol('a') + +symbol('n')).bang_find(e)) !=string::npos)
      cout << p << " " << texte.substr(p, e.first.offset()-p) << " ";
```

```
10 Hautcastel

24 an 144 ann 172 ann 254 an 377 an 455 an 493 ann 649 an 672 an
682 an 821 an 1005 an 1028 an 1086 an 1167 an 1245 an 1259 an 1324
```


Fonction entity()

Classe de symboles terminaux

Caractère quelconque	entity()
Caractère c	entity(char c) éq. symbol(char c)
Caractère du tableau tc	entity(char* tc)
Caractère de la chaîne de caractères s	entity(string s)
Caractère alphanumérique	entity(isalnum)
Caractère alphabétique	entity(isalpha)
Caractère décimal	entity(isdigit)
Caractère majuscule	entity(islower)
Caractère minuscule	entity(isupper)
Caractère de ponctuation	entity(ispunct)

Classe de symboles optionnelle	*entity(…)
Classe de symboles multiple	+entity(…)

Opérateur de concaténation de classes	(entity(…) + entity(…))
Opérateur logique entre classes	(entity(…) | entity(…))

testEntity.cpp

Recherche de noms propres dans un segment

```
int NomPropre(const_edge<>& edge_ ) {
      string maj = "ABCDEFGHIJKLMNOPQRSTUVWXYZ";
      string min = "abcdefghijklmnopqrstuvwxyzéèà";
        return ( entity(maj) + +entity(min) ).bang_find(edge_);
    }

int main() {
string texte;
file2string("Data/livres/adelaide.txt", texte);

// recherche en boucle du motif maj{min}
const_edge<> e = *(new const_edge<>(texte, 0, texte.size()));
int p;
while ((p = NomPropre(e)) != std::string::npos)
cout << p << " " << texte.substr(p, e.first.offset()-p) << " ";}
```

```
0 Madame 10 Hautcastel 158 Frédéric 167 Rothbanner 250 Hermansburg
276 Ce 313 Rien 430 Le 438 Ma 512 Bernstein 677 Le 863 Son 867
Altesse 875 Royale 968 Bref 1035 Au 1161 Cependant 1388 De 1400
Rothbanner 1571 Ce 1616 Pour 1937 Hermansburg 2062 Elle 2147 Pour
```


Modélisation

Représentation des règles de production par des fonctions d'appariement

```
static size_t sp(const_edge<>& e) { return symbol(' ') match(e);}
```

Appel des fonctions d'appariement avec l'adaptateur de fonction rule()

```
static size_t start(const_edge<>& e) { return rule(sp) match(e);}
```

rule(&*r*) avec r est une fonction globale ou une fonction membre statique

rule(*O*,&C::*r*) avec O est un classe-grammaire, C une instance de O et r une fonction membre non statique

Appel avec trace pour le déverminage de grammaires

CTTL_RULE(&C::*r*), CTTL_MEMBER_RULE(*O*,&*r*), CTTL_STATIC_RULE(*r*)

testRule.cpp

Définition de la grammaire

```
class Grammaire {
static size_t item( const_edge<policy_space<> >& e) {
      return (symbol("caractere") | symbol("mot") | symbol("ligne") |
      symbol("page") ).match(e); }
static size_t dir( const_edge<policy_space<> >& e) {
      return (symbol("haut") | symbol("bas") | symbol("gauche") |
      symbol("droite") ).match(e); }
static size_t ecmd( const_edge<policy_space<> >& e) {
      return ( symbol("fin") + *symbol("inserer") ).match(e);}
static size_t icmd( const_edge<policy_space<> >& e) {
      return symbol("inserer").match(e);}
static size_t dcmd( const_edge<policy_space<> >& e) {
      return ( symbol("detruire") + *rule(item) ).match(e); }
static size_t mcmd( const_edge<policy_space<> >& e) {
      return ( symbol("bouger") + rule(dir) ).match(e); }

public:
static size_t start( const_edge<policy_space<> >& e) {
      return ( rule(mcmd) | rule(dcmd) | rule(icmd) + rule(ecmd)
      ).match(e);}
};
```


testRule.cpp

Appartenance à la grammaire

```
void appartient(string s) {
const_edge<policy_space<> > e = *(new const_edge<policy_space<> >(s,
0, s.size()));

      if (rule(Grammaire::start).match(e) == 0)
      cout << s << " appartient au langage" << endl;
else
      cout << s << " n'appartient pas au langage" << endl;
}

int main() {
      appartient ("bouger bas");
      appartient ("detruire caractere");
      appartient ("bouger caractère");

return 0;
}
```

```
bouger bas appartient au langage
detruire caractere appartient au langage
bouger caractère n'appartient pas au langage
```